




信息论

第一讲 · 从「surprise」到误差界

Oxford B8.4 · 2024--25

依据手写笔记整理的读填笔记

2026 年 7 月 25 日

dyed in indigo, madder & weld; ruled in iron-gall. woven on LOOM.

一条主线与知识地图

□□□□

概率分布告诉我们哪些结果更可能发生。信息论先把它变成对数「surprise」，再对它作平均、比较和条件化，得到熵、散度与互信息。接下来的内容说明这些量在比较和处理中受到哪些结构性限制，并最终把剩余不确定性转化为估计误差的下界。

知识地图：从 surprise 到误差界的八站路线

站	核心对象	打开什么问题
1	$-\log p(x)$: surprise	把概率分布变成可加的信息刻度
2	$H(X)$: 平均 surprise	度量不确定性，并刻画最大熵分布
3	$D(p q)$: 模型失配	以有方向的方式比较真实分布与参照分布
4	$I(X;Y)$ 与 $H(Y X)$	区分共享的信息与仍然剩余的不确定性
5	log-sum 与散度不等式	得到非负性、链式法则与凸性
6	条件互信息	得到数据处理：变换不能创造信息
7	约束下的熵	给出取值范围、取等条件，以及确定性映射或混合的影响
8	Fano 不等式	把剩余不确定性转成解码误差的下界

全文约定

未注明底数时， $\log = \log_2$ ，信息量的单位为比特。对于零概率项，约定 $0 \log 0 = 0$ 。

目录

一条主线与知识地图	1
第一讲 · 从「surprise」到误差界	3
1 概率分布与「surprise」	3
2 熵：平均「surprise」	4
3 散度：比较两个分布	5
4 共享信息与剩余不确定性	7
5 散度不等式	9
6 信息只会在处理中损失	11
7 约束下的熵	13
8 Fano 不等式	16

第一讲 · 从「SURPRISE」到误差界

从概率分布出发构造四个基本量：surprise、熵、散度与互信息，并用条件熵把它们连接起来；再用 log-sum、非负性与链式法则说明数据处理不可能创造信息，最后把解码错误转化为熵的界。

■ 1 概率分布与「SURPRISE」

□□□□ 概率分布是研究对象，「surprise」是它的一个对数。

在度量信息之前，先区分随机变量与它的分布。对离散随机变量，概率质量函数记录每个可能取值出现的概率。同一个分布也可以写成概率测度，或用累积分布函数来描述。

分布的三种写法

定义 1.1 (概率质量函数). 设离散随机变量 X 的取值字母表为 $\mathcal{X}$ 。它的概率质量函数为

$$p : \mathcal{X} \rightarrow [0, 1], \quad p(x) = \mathbb{P}(X = x).$$

需要强调随机变量时，也把它写成 p_X 。

定义 1.2 (分布与累积分布函数). 随机变量 X 的分布记为 P_X 。对于取值空间中的任意集合 A ，定义

$$P_X(A) = \mathbb{P}(X \in A).$$

若 X 是实值随机变量，则它的累积分布函数定义为

$$F_X(y) = \mathbb{P}(X \leq y), \quad y \in \mathbb{R}.$$

Your turn. 补全下面的对应关系：

$$p_X(x) = \underline{\mathbb{P}(X = x)}, \quad P_X((a, b)) = \underline{\mathbb{P}(a < X < b)}.$$

? $p_X(x) = \mathbb{P}(X = x)$, $P_X((a, b)) = \mathbb{P}(a < X < b)$ 。

为什么「surprise」是对数

定义 1.3 (事件的「surprise」). 设 $s(A)$ 是事件 A 的「surprise」。我们要求它连续依赖于 $\mathbb{P}(A)$ ，随 $\mathbb{P}(A)$ 增大而减小，并且当 A, B 独立时满足

$$s(A \cap B) = s(A) + s(B).$$

在选择对数底数的自由之外，这些要求导出

$$s(A) = -\log P(A).$$

Your turn. 若独立事件满足 $P(A) = 1/2$ 、 $P(B) = 1/4$ ，则

$$s(A) = \underline{1}, \quad s(B) = \underline{2}, \quad s(A \cap B) = \underline{3} \text{ 比特}.$$

? 答案依次为
1, 2, 3 比特。独立性给出
 $P(A \cap B) =$
 $P(A)P(B) = 1/8$ 。

■ 2 熵：平均「SURPRISE」

□□□□ 熵把所有可能结果的「surprise」取平均。

$-\log p(x)$ 描述某一个结果的「surprise」。熵对它取期望，因此熵依赖于 X 的分布，而不依赖于这一次实际观察到了哪个取值。

定义 2.1 (b 进制熵). 设离散随机变量 X 的字母表为 $\mathcal{X}$ ，则

$$H_b(X) = - \sum_{x \in \mathcal{X}} p_X(x) \log_b p_X(x) = \mathbb{E}[-\log_b p_X(X)].$$

约定 $0 \log_b 0 = 0$ 。若无特别说明，取 $b = 2$ 。

注 2.2. 熵只依赖于 p_X ，因此 $H(X)$ 、 $H(p_X)$ 和 $H(p)$ 可能表示同一个数。

伯努利随机变量

例 2.3 (二元熵). 设 $\mathcal{X} = \{H, T\}$ ，并且 $P(X = H) = p$ 、 $P(X = T) = 1 - p$ 。则

$$H(X) = -p \log p - (1 - p) \log(1 - p).$$

在这个特殊情形下，也常把它写成 $H(p)$ 。

Your turn. 用公式补全三个关键取值：

$$H(0) = \underline{0}, \quad H\left(\frac{1}{2}\right) = \underline{1}, \quad H(1) = \underline{0} \text{ 比特}.$$

画出 $0 \leq p \leq 1$ 时的大致曲线，并标出最高点。

? 三个值依次是 0, 1, 0。曲线关于 $p = 1/2$ 对称, 并在这里达到最高点。

联合熵

定义 2.4 (联合熵). 令 $X = (X_1, X_2)$, 其联合概率质量函数为 $p_{X_1 X_2}$, 则

$$H(X_1, X_2) = - \sum_{x_1 \in \mathcal{X}_1} \sum_{x_2 \in \mathcal{X}_2} p_{X_1 X_2}(x_1, x_2) \log p_{X_1 X_2}(x_1, x_2).$$

命题 2.5 (独立时的可加性). 若 X_1 与 X_2 独立, 则

$$H(X_1, X_2) = H(X_1) + H(X_2).$$

证明. 独立性给出 $p_{X_1 X_2}(x_1, x_2) = p_{X_1}(x_1)p_{X_2}(x_2)$ 。把它代入定义 2.4, 并拆开乘积的对数:

$$\begin{aligned} H(X_1, X_2) &= - \sum_{x_1, x_2} p_{X_1}(x_1)p_{X_2}(x_2)(\log p_{X_1}(x_1) + \log p_{X_2}(x_2)) \\ &= - \sum_{x_1} p_{X_1}(x_1) \log p_{X_1}(x_1) \sum_{x_2} p_{X_2}(x_2) \\ &\quad - \sum_{x_2} p_{X_2}(x_2) \log p_{X_2}(x_2) \sum_{x_1} p_{X_1}(x_1) \\ &= H(X_1) + H(X_2). \end{aligned}$$

最后一步使用了两个边缘概率质量函数之和均为 1。

Your turn. 复述可加性证明中最关键的一步:

$$\log(p_{X_1}(x_1)p_{X_2}(x_2)) = \underline{\log p_{X_1}(x_1) + \log p_{X_2}(x_2)}.$$

? $\log p_{X_1}(x_1) + \log p_{X_2}(x_2)$ 。

3 散度: 比较两个分布

□□□□ KL 散度并非距离, 但距离的直觉很好用。

$D(p||q)$ 描述真实分布为 p 、而假设分布为 q 时的无效性。它是不对称的, 因此并非严格数学意义上两个分布之间的距离; 不过, 把它视作一种有方向的“距离”通常非常有用。

定义 3.1 (Kullback-Leibler 散度). 设 p, q 是字母表 $\mathcal{X}$ 上的概率质量函数, 则

$$D(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)}.$$

约定 $0 \log(0/q) = 0$ 。若存在某个 x 使得 $p(x) > 0$ 而 $q(x) = 0$, 则 $D(p\|q) = \infty$ 。

期望形式与熵形式

若 $X \sim p$, 则

$$\begin{aligned} D(p\|q) &= \mathbb{E}_{X \sim p} \left[\log \frac{p(X)}{q(X)} \right] \\ &= -\mathbb{E}_{X \sim p} [\log q(X)] - H(X). \end{aligned}$$

Your turn. 补全下面的代数步骤:

$$\mathbb{E}_p \left[\log \frac{p(X)}{q(X)} \right] = \mathbb{E}_p [\log p(X)] - \mathbb{E}_p [\log q(X)] = \underline{-H(X) - \mathbb{E}_p [\log q(X)]}.$$

? 答案是 $-H(X) - \mathbb{E}_p [\log q(X)]$ 。

次序不能交换

例 3.2 (非对称性). 在 $\mathcal{X} = \{0, 1\}$ 上, 令

$$p = (1/2, 1/2), \quad q = (1, 0).$$

由于 $q(1) = 0$ 而 $p(1) > 0$, 所以 $D(p\|q) = \infty$; 但

$$D(q\|p) = \log \frac{1}{1/2} = 1 \text{ 比特}.$$

因此 $D(p\|q)$ 与 $D(q\|p)$ 不一定相等。

Your turn. 用一句话解释: 为什么第一个方向是无穷, 而反向却是有限的?

$D(p\|q)$ 求和 $p(x) \log \frac{p(x)}{q(x)}$; 由于 $p(1) > 0$ 而 $q(1) = 0$, 项 $\log \frac{p(1)}{q(1)} = \log \infty$ 爆炸。反向时, 凡 $q(x) > 0$ 的 x 都有 $p(x) > 0$, 因此不出现无穷项。

? $p(1) > 0 = q(1)$ 使 $D(p\|q) = \infty$; 反向的支撑上没有这种项。

与均匀分布比较

命题 3.3 (均匀参照分布). 若 q 是有限字母表 $\mathcal{X}$ 上的均匀分布, 且 $X \sim p$, 则

$$D(p\|q) = \log |\mathcal{X}| - H(X).$$

证明. 因为 $q(x) = 1/|\mathcal{X}|$,

$$\begin{aligned} D(p\|q) &= \sum_x p(x) \log p(x) + \sum_x p(x) \log |\mathcal{X}| \\ &= -H(X) + \log |\mathcal{X}| \sum_x p(x) \\ &= \log |\mathcal{X}| - H(X). \end{aligned}$$

最后一步使用了 $\sum_x p(x) = 1$ 。 ■

Your turn. 复述均匀参照分布证明中的关键化简:

$$D(p\|q) = -H(X) + \log |\mathcal{X}| \sum_x p(x) = \underline{\log |\mathcal{X}| - H(X)}.$$

? $\log |\mathcal{X}| - H(X)$.

■ 4 共享信息与剩余不确定性

□□□□ 互信息度量一个随机变量包含另一个随机变量的信息量; 条件熵度量剩余的不确定性。

互信息 $I(X; Y)$ 是一个随机变量包含另一个随机变量信息量的度量, 也就是已知一个随机变量时, 另一个随机变量不确定度的减少量。

定义 4.1 (互信息). 设离散随机变量 X, Y 分别取值于 $\mathcal{X}, \mathcal{Y}$, 则

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{XY}(x, y) \log \frac{p_{XY}(x, y)}{p_X(x)p_Y(y)}.$$

等价地,

$$I(X; Y) = D(p_{XY} \| p_X p_Y).$$

熵的表达式

在联合分布下取期望,

$$\begin{aligned} I(X; Y) &= \mathbb{E} \left[\log \frac{p_{XY}(X, Y)}{p_X(X)p_Y(Y)} \right] \\ &= H(X) + H(Y) - H(X, Y). \end{aligned}$$

对数比中的三个期望完整写为

$$\mathbb{E}[\log p_{XY}(X, Y)] - \mathbb{E}[\log p_X(X)] - \mathbb{E}[\log p_Y(Y)] = -H(X, Y) + H(X) + H(Y).$$

条件熵

定义 4.2 (条件熵). Y 在给定 X 时的条件熵为

$$H(Y | X) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{XY}(x, y) \log p_{Y|X}(y | x).$$

等价地，它是各个条件分布之熵的平均：

$$H(Y | X) = \sum_{x \in \mathcal{X}} p_X(x) H(Y | X = x).$$

命题 4.3 (链式法则).

$$H(Y | X) = H(X, Y) - H(X), \quad H(X | Y) = H(X, Y) - H(Y).$$

证明. 贝叶斯公式给出 $p_{Y|X}(y | x) = p_{XY}(x, y)/p_X(x)$ 。把这个比值代入定义 4.2：

$$\begin{aligned} H(Y | X) &= - \sum_{x,y} p_{XY}(x, y) \log \frac{p_{XY}(x, y)}{p_X(x)} \\ &= - \sum_{x,y} p_{XY}(x, y) \log p_{XY}(x, y) + \sum_{x,y} p_{XY}(x, y) \log p_X(x) \\ &= H(X, Y) + \sum_x p_X(x) \log p_X(x) \\ &= H(X, Y) - H(X). \end{aligned}$$

交换 X 与 Y ，同理得到 $H(X | Y) = H(X, Y) - H(Y)$ 。 ■

Your turn. 复述链式法则证明中最关键的对数拆分：

$$\log(p_X(x)p_{Y|X}(y | x)) = \underline{\log p_X(x) + \log p_{Y|X}(y | x)}.$$

? $\log p_X(x) + \log p_{Y|X}(y | x)$ 。

把所有恒等式放在一起

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = H(Y) - H(Y | X) = H(X) - H(X | Y).$$

■ 5 散度不等式

□□□□ log-sum 不等式把逐点的比值变成整体的比较。

KL 散度不只是一个公式。它最有用的性质都来自同一个动作：把正项分组，对它们的比值使用凸性，并追踪取等条件。非负性、链式法则、粗粒化与凸性背后都是这个机制。

■ **引理 5.1 (信息不等式).** 对同一字母表上的概率质量函数 p, q ,

$$D(p\|q) \geq 0,$$

且等号成立当且仅当 $p = q$ 。

证明. 若存在 $p(x) > 0$ 但 $q(x) = 0$ 的 x , 则 $D(p\|q) = +\infty$ 。否则, 令 $X \sim p$ 且 $S = \{x : p(x) > 0\}$ 。对凸函数 $-\log$ 使用 Jensen 不等式:

$$\begin{aligned} D(p\|q) &= \mathbb{E}_p \left[-\log \frac{q(X)}{p(X)} \right] \\ &\geq -\log \mathbb{E}_p \left[\frac{q(X)}{p(X)} \right] = -\log \sum_{x \in S} q(x) \geq -\log 1 = 0. \end{aligned}$$

Jensen 中取等要求 $q(x)/p(x)$ 在 S 上为常数; 第二个不等式取等要求 q 在 S 外没有概率质量。再由归一化可知该常数只能为 1, 故 $p = q$ 。 ■

■ **定理 5.2 (log-sum 不等式).** 设 $a_1, \dots, a_n$ 与 $b_1, \dots, b_n$ 非负, 并令 $a = \sum_i a_i$ 、 $b = \sum_i b_i$, 则

$$\sum_{i=1}^n a_i \log \frac{a_i}{b_i} \geq a \log \frac{a}{b}.$$

若所有相关项均为正, 则等号成立当且仅当 a_i/b_i 不依赖于 i 。

证明. 边界情形由零项的通常约定直接得到。在非平凡且有限的情形 $a, b > 0$ 下, 令 $\alpha_i = a_i/a$ 、 $\beta_i = b_i/b$ 。于是

$$\begin{aligned} \sum_i a_i \log \frac{a_i}{b_i} &= a \log \frac{a}{b} + a \sum_i \alpha_i \log \frac{\alpha_i}{\beta_i} \\ &= a \log \frac{a}{b} + a D(\alpha\|\beta) \\ &\geq a \log \frac{a}{b}, \end{aligned}$$

其中最后一步使用引理 5.1。等号成立恰好等价于 $\alpha = \beta$, 也就是在公共支撑上 $a_i/b_i = a/b$ 。 ■

Your turn. log-sum 不等式何时取等?

$$\frac{a_1}{b_1} = \dots = \frac{a_n}{b_n} = \underline{\frac{a}{b}}.$$

? 所有比值都等于同一个值 a/b 时取等。

模型失配的链式法则

对联合概率质量函数 $p_{XY} = p_X p_{Y|X}$ 与 $q_{XY} = q_X q_{Y|X}$, 定义条件散度

$$D(p_{Y|X} \| q_{Y|X} | p_X) := \sum_x p_X(x) D(p_{Y|X}(\cdot | x) \| q_{Y|X}(\cdot | x)).$$

命题 5.3 (散度的链式法则).

$$D(p_{XY} \| q_{XY}) = D(p_X \| q_X) + D(p_{Y|X} \| q_{Y|X} | p_X).$$

证明. 分解两个联合分布并拆开对数:

$$\begin{aligned} D(p_{XY} \| q_{XY}) &= \sum_{x,y} p_{XY}(x,y) \log \frac{p_X(x) p_{Y|X}(y|x)}{q_X(x) q_{Y|X}(y|x)} \\ &= \sum_x p_X(x) \log \frac{p_X(x)}{q_X(x)} + \sum_x p_X(x) \sum_y p_{Y|X}(y|x) \log \frac{p_{Y|X}(y|x)}{q_{Y|X}(y|x)}. \end{aligned}$$

这正是结论中的两项。

推论 5.4 (边缘化不会增大散度).

$$D(p_{XY} \| q_{XY}) \geq D(p_X \| q_X).$$

证明. 两边之差是命题 5.3 中的条件散度; 它是非负散度的平均。

混合两对分布

命题 5.5 (联合凸性). 对概率质量函数 p_1, p_2, q_1, q_2 以及 $0 \leq \lambda \leq 1$,

$$\begin{aligned} D(\lambda p_1 + (1-\lambda)p_2 \| \lambda q_1 + (1-\lambda)q_2) \\ \leq \lambda D(p_1 \| q_1) + (1-\lambda) D(p_2 \| q_2). \end{aligned}$$

证明. 对每个结果 x , 在 log-sum 不等式中取 $a_1 = \lambda p_1(x)$ 、 $a_2 = (1-\lambda)p_2(x)$, 并用 q_1, q_2 构造相应的 b_1, b_2 . 再对 x 求和, 即得结论。

Your turn. 在散度链式法则中，减去边缘项后还剩什么？

$$D(p_{XY} \| q_{XY}) - D(p_X \| q_X) = \underline{D(p_{Y|X} \| q_{Y|X} \mid p_X)}.$$

? 余项是条件散度的平均，因此非负。

■ 6 信息只会处理中损失

□□□□ 先条件化，再展开，最后丢掉一个非负项。

互信息可以看作共享的证据。它非负且对称，可以按变量逐个展开；对观测结果做后处理，不可能凭空制造关于信源的新信息。

核心恒等式

命题 6.1 (互信息的性质). 对离散随机变量 X, Y ,

$$I(X; Y) \geq 0.$$

等号成立当且仅当 X 与 Y 独立。此外，

$$I(X; Y) = I(Y; X),$$

$$I(X; Y) = H(X) - H(X \mid Y) = H(Y) - H(Y \mid X).$$

证明. 由定义 4.1,

$$I(X; Y) = D(p_{XY} \| p_X p_Y).$$

信息不等式给出非负性；等号成立恰好对应 $p_{XY} = p_X p_Y$ ，也就是独立性。交换 X, Y 不改变定义中的对数比，因此互信息对称。最后两个熵恒等式来自命题 4.3 中的链式法则。 ■

定义 6.2 (条件互信息). 已知 Z 后， X 与 Y 的共享信息定义为

$$I(X; Y \mid Z) := \sum_z p_Z(z) D(p_{XY|Z}(\cdot, \cdot \mid z) \| p_{X|Z}(\cdot \mid z) p_{Y|Z}(\cdot \mid z)).$$

因此 $I(X; Y \mid Z) \geq 0$ 。

命题 6.3 (互信息的链式法则).

$$I(X_1, \dots, X_n; Y) = \sum_{i=1}^n I(X_i; Y \mid X_1, \dots, X_{i-1}).$$

证明. 逐项使用条件互信息的熵表达式

$$I(U; Y | V) = H(Y | V) - H(Y | U, V),$$

其中 $U = X_i$ 、 $V = (X_1, \dots, X_{i-1})$ 。于是求和中的相邻条件熵发生望远镜消去：

$$\begin{aligned} \sum_{i=1}^n I(X_i; Y | X_1, \dots, X_{i-1}) &= \sum_{i=1}^n [H(Y | X_1, \dots, X_{i-1}) - H(Y | X_1, \dots, X_i)] \\ &= H(Y) - H(Y | X_1, \dots, X_n). \end{aligned}$$

最后一个表达式正是 $I(X_1, \dots, X_n; Y)$ 。 ■

Your turn. 展开两个变量的情形：

$$I(X_1, X_2; Y) = I(X_1; Y) + \underline{I(X_2; Y | X_1)}.$$

? 缺少的一项是 $I(X_2; Y | X_1)$ 。

数据处理

定义 6.4 (Markov 链). 若给定 Y 后 X 与 Z 条件独立，就记作 $X \rightarrow Y \rightarrow Z$ 。等价地，

$$p_{Z|XY}(z | x, y) = p_{Z|Y}(z | y).$$

定理 6.5 (数据处理不等式). 若 $X \rightarrow Y \rightarrow Z$ 构成 Markov 链，则

$$I(X; Z) \leq I(X; Y).$$

证明. 按两种顺序展开同一个互信息：

$$I(X; Y, Z) = I(X; Y) + I(X; Z | Y) = I(X; Z) + I(X; Y | Z).$$

Markov 条件给出 $I(X; Z | Y) = 0$ ，而条件互信息非负。因此

$$I(X; Y) = I(X; Z) + I(X; Y | Z) \geq I(X; Z).$$
■

推论 6.6 (确定性处理). 对任意函数 f ，

$$I(X; f(Y)) \leq I(X; Y).$$

证明. 因为 $f(Y)$ 完全由 Y 决定，所以 $X \rightarrow Y \rightarrow f(Y)$ 构成 Markov 链。应用定理 6.5 即得结论。 ■

Your turn. 说出数据处理不等式证明中的两个关键动作：

(1) 按两种顺序展开 $I(X;Y,Z)$; (2) 用 Markov 条件 $I(X;Z|Y) = 0$, 再用非负性 $I(X;Y|Z) \geq 0$ 。

? 两个动作: (1) 按两种顺序展开 $I(X;Y,Z)$; (2) 使用 $I(X;Z|Y) = 0$ 与 $I(X;Y|Z) \geq 0$ 。

7 约束下的熵

□□□□ 支撑、条件化与确定性映射都会限制不确定性。

熵不能任意变化。有限字母表固定了它的取值范围，条件化只能消除不确定性，而确定性映射只能合并结果。取等条件进一步告诉我们：什么时候信息没有损失。

取值范围与取等条件

命题 7.1 (熵的界). 若 X 取值于有限字母表 $\mathcal{X}$, 则

$$0 \leq H(X) \leq \log |\mathcal{X}|.$$

下界成立当且仅当 X 为常量；上界成立当且仅当 X 在 $\mathcal{X}$ 上均匀分布。

证明. 每一项 $-p_X(x) \log p_X(x)$ 都非负，因此得到下界。等号要求某个结果的概率为 1。对上界，令 u 为 $\mathcal{X}$ 上的均匀分布。命题 3.3 中的均匀参照恒等式给出

$$D(p_X \| u) = \log |\mathcal{X}| - H(X) \geq 0.$$

信息不等式取等当且仅当 $p_X = u$ 。 ■

Your turn. 补全证明上界所用的恒等式：

$$D(p_X \| u) = \log |\mathcal{X}| - \underline{H(X)}.$$

? 使用 $D(p_X \| u) = \log |\mathcal{X}| - H(X) \geq 0$ 。

命题 7.2 (条件化降低熵). 对离散随机变量 X, Y ,

$$0 \leq H(X|Y) \leq H(X).$$

此外，

$$H(X|Y) = H(X) \iff X \text{ 与 } Y \text{ 独立},$$

而

$$H(X|Y) = 0 \iff X = f(Y) \text{ 几乎处处成立}$$

其中 f 为某个函数。

证明. 条件熵是非负熵的平均, 因此

$$H(X | Y) = \sum_y p_Y(y) H(X | Y = y) \geq 0.$$

它为零当且仅当每个满足 $p_Y(y) > 0$ 的条件分布都是点质量; 这等价于 $X = f(Y)$ 几乎处处成立。

对上界, 命题 6.1 给出

$$H(X) - H(X | Y) = I(X; Y) \geq 0.$$

等号成立当且仅当 $I(X; Y) = 0$, 也就是 X, Y 独立。 ■

Your turn. 配对两个取等条件:

$$\begin{aligned} H(X | Y) = H(X) &\iff \underline{X \perp Y}, \\ H(X | Y) = 0 &\iff \underline{X = f(Y) \text{ a.s.}}. \end{aligned}$$

? 上界取等意味着独立; 条件熵为零意味着 X 由 Y 决定。

■ **命题 7.3** (熵的链式法则与次可加性). 对离散随机变量 $X_1, \dots, X_n$,

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}) \leq \sum_{i=1}^n H(X_i).$$

不等式取等当且仅当这些随机变量相互独立。

证明. 反复使用二元链式法则 $H(U, V) = H(U) + H(V | U)$, 再逐项应用

$$H(X_i | X_1, \dots, X_{i-1}) \leq H(X_i).$$

取等意味着每个 X_i 都与它之前的变量独立, 这等价于相互独立。 ■

确定性映射与碰撞

■ **命题 7.4** (函数不会增大熵). 对任意函数 f ,

$$H(f(X)) \leq H(X).$$

等号成立当且仅当 f 在 X 的支撑上为单射。

证明. 因为 $f(X)$ 由 X 完全决定,

$$H(X, f(X)) = H(X) + H(f(X) | X) = H(X).$$

按另一顺序展开:

$$H(X, f(X)) = H(f(X)) + H(X | f(X)) \geq H(f(X)).$$

等号成立当且仅当可以从 $f(X)$ 恢复 X , 也就是 f 在 X 的支撑上为单射。 ■

Your turn. 哪个非负项度量了 f 丢失的信息?

$$H(X) - H(f(X)) = \underline{H(X | f(X))}.$$

? 丢失的信息是 $H(X | f(X))$ 。

命题 7.5 (碰撞概率). 令 X' 为 X 的独立同分布副本, 则

$$P(X = X') \geq 2^{-H(X)}.$$

等号成立当且仅当 X 在其支撑上均匀分布。

证明. 对凸函数 $t \mapsto 2^t$ 使用 Jensen 不等式:

$$2^{-H(X)} = 2^{E[\log p_X(X)]} \leq E[2^{\log p_X(X)}] = E[p_X(X)].$$

独立同分布给出

$$E[p_X(X)] = \sum_x p_X(x)^2 = P(X = X').$$

Jensen 取等当且仅当 $\log p_X(X)$ 在支撑上为常数, 也就是 X 在支撑上均匀分布。 ■

Your turn. 补全碰撞恒等式:

$$E[p_X(X)] = \sum_x p_X(x)^2 = \underline{P(X = X')}.$$

? 对独立副本 X'
 $\sum_x p_X(x)^2 =$
 $P(X = X')$ 。

混合分布

命题 7.6 (熵的凹性). 对同一字母表上的概率质量函数 p, q 以及 $0 \leq \lambda \leq 1$,

$$H(\lambda p + (1 - \lambda)q) \geq \lambda H(p) + (1 - \lambda)H(q).$$

证明. 函数 $g(t) = -t \log t$ 在 $[0, 1]$ 上为凹函数。因此对每个 x ,

$$g(\lambda p(x) + (1 - \lambda)q(x)) \geq \lambda g(p(x)) + (1 - \lambda)g(q(x)).$$

对 x 求和即得结论。 ■

Your turn. 写出熵的凹性背后的一元函数:

$$g(t) = \underline{-t \log t}.$$

? 熵是凹函数项
 $g(t) = -t \log t$ 的
和。

8 FANO 不等式

□□□□ 一次解码错误只会留下可控数量的不确定性。

把 Y 看作对 X 的猜测。Fano 不等式把猜错的概率转化为一个上界：观察 Y 后，关于 X 还可能剩下多少不确定性。

定义 8.1 (错误指示变量). 设 X, Y 都取值于同一个有限字母表 $\mathcal{X}$ ，且 $|\mathcal{X}| \geq 2$ 。定义

$$Z = \mathbf{1}_{\{X \neq Y\}}, \quad P_e = \mathbb{P}(X \neq Y) = \mathbb{P}(Z = 1).$$

二元熵函数定义为

$$h_2(t) = -t \log t - (1-t) \log(1-t).$$

定理 8.2 (Fano 不等式).

$$H(X | Y) \leq h_2(P_e) + P_e \log(|\mathcal{X}| - 1).$$

等价地，

$$H(X | Y) \leq H(Z) + \mathbb{P}(X \neq Y) \log(|\mathcal{X}| - 1).$$

证明. 指示变量 Z 由 (X, Y) 完全决定，因此 $H(Z | X, Y) = 0$ 。按两种顺序使用链式法则：

$$\begin{aligned} H(X | Y) &= H(X, Z | Y) \\ &= H(Z | Y) + H(X | Y, Z) \\ &\leq H(Z) + H(X | Y, Z). \end{aligned}$$

当 $Z = 0$ 时猜测正确，即 $X = Y$ ，所以

$$H(X | Y, Z = 0) = 0.$$

当 $Z = 1$ 且 $Y = y$ 时， $X = y$ 被排除，只剩至多 $|\mathcal{X}| - 1$ 个可能值。由命题 7.1，

$$H(X | Y = y, Z = 1) \leq \log(|\mathcal{X}| - 1).$$

对 Y 与 Z 的两个取值求平均，得到

$$H(X | Y, Z) \leq P_e \log(|\mathcal{X}| - 1).$$

最后， Z 是参数为 P_e 的 Bernoulli 随机变量，因此 $H(Z) = h_2(P_e)$ 。 ■

Your turn. 回忆证明中的两种情形：

$$Z = 0 : \quad X = Y, \quad H(X | Y, Z = 0) = \underline{0},$$

$$Z = 1 : \quad X \text{ 至多有 } \underline{|\mathcal{X}| - 1} \text{ 个可能值.}$$

？猜对时没有不确定性；猜错时至多还剩 $|\mathcal{X}| - 1$ 个候选。

推论 8.3 (一比特形式). 因为二元熵至多为一比特,

$$H(X | Y) \leq 1 + P(X \neq Y) \log(|\mathcal{X}| - 1).$$

交换 X, Y 还得到配套的界

$$H(Y | X) \leq 1 + P(X \neq Y) \log(|\mathcal{X}| - 1).$$

证明. 在定理 8.2 中使用 $h_2(P_e) \leq 1$ 。对第二个不等式, 把同一定理应用于 (Y, X) ; 错误事件 $\{Y \neq X\}$ 及其概率都不变。 ■

如何理解这个界

正向读法是

$$P_e \text{ 很小} \implies H(X | Y) \text{ 很小}.$$

更常用的是反向读法: 把同一个不等式移项, 解出 P_e 。当 $|\mathcal{X}| > 2$ 时, 推论 8.3 可以改写成

$$P_e \geq \frac{H(X | Y) - 1}{\log(|\mathcal{X}| - 1)}.$$

因此, 若观察 Y 后仍有很大的不确定性, 那么任何基于 Y 的估计器都不可能具有很小的错误概率。这里都是不等式而不是等式: 松弛可能来自 $h_2(P_e) \leq 1$, 也可能来自“猜错时至多有 $|\mathcal{X}| - 1$ 个候选”这一上界。