




信息论

第二讲 · 从码字到典型序列

Oxford B8.4 · 2024--25

fanzuituanhuo

August 5, 2026

dyed in indigo, madder & weld; ruled in iron-gall. woven on LOOM.

一条主线与知识地图

□□□□

信源编码把每个信源符号替换成一个有限字符串。编码质量有两个侧面：以期望码长衡量的效率，以及在码字拼接后检验的可译性。Kraft-McMillan 控制哪些码长能够装下；AEP 则说明为什么熵是长 i.i.d. 分组编码的自然尺度。

目前的知识地图

站	对象	要回答的问题
1	$C : \mathcal{X} \rightarrow \mathcal{D}^*$	每个信源符号由哪个有限字符串表示？
2	$L(C) = \mathbb{E}[\ell(X)]$	平均要使用多少个编码符号？
3	$C^* : \mathcal{X}^* \rightarrow \mathcal{D}^*$	码字拼接起来以后还能否唯一解码？
4	$\sum_x D^{-\ell(x)} \leq 1$	哪些码长列表能够对应可译码？
5	$-n^{-1} \log p(X^n) \rightarrow H(X)$	长分组的概率质量集中在哪里？

全文约定

信源字母表 $\mathcal{X}$ 有限， $\mathcal{D}^*$ 表示由 D 元编码字母表 $\mathcal{D}$ 中的符号组成的所有有限长字符串。例子通常取 $\mathcal{D} = \{0, 1\}$ 。

目录

一条主线与知识地图	1
第二讲 · 信源编码	3
1 编码、码长与可译性	3
2 Kraft-McMillan: 码长何时装得下	5
3 AEP 与典型序列	7

第二讲 · 信源编码

先给信源符号分配字符串，再按照信源分布计算平均长度，最后提出决定性问题：拼接操作是否保留了足够的结构，使我们能够逆转编码过程？对于长 i.i.d. 分组，再找出承载几乎全部概率的典型序列，从而看见熵就是序列数量的指数增长率。

1 编码、码长与可译性

□□□□ 一个码字标记一个符号；扩展码还必须保住整个符号序列。

编码从一个“信源符号到有限字符串”的映射开始。短字符串能够节省空间，但不同的符号，乃至不同的信源序列，都必须保持可区分。因此，期望码长与可译性必须放在一起研究。

从信源符号到码字

定义 1.1 (信源编码). 设随机变量 X 的有限字母表为 $\mathcal{X}$ 。一个 D 元信源编码是映射

$$C: \mathcal{X} \rightarrow \mathcal{D}^*,$$

其中 $\mathcal{D}^*$ 是 D 元字母表 $\mathcal{D}$ 上所有 有限长字符串 的集合。字符串 $C(x)$ 称为 x 的码字， $\ell(x) = |C(x)|$ 是它的码长。

例如，若 $\mathcal{X} = \{\text{红}, \text{蓝}\}$ 且 $\mathcal{D} = \{0, 1\}$ ，可以取 $C(\text{红}) = 00$ 、 $C(\text{蓝}) = 11$ 。

定义 1.2 (期望码长). 若 X 的概率质量函数为 p ，编码 C 的期望码长定义为

$$L(C) = \mathbb{E}[\ell(X)] = \sum_{x \in \mathcal{X}} p(x) \ell(x).$$

例 1.3 (与熵匹配的二进制编码). 令 $\mathcal{X} = \{1, 2, 3, 4\}$ ，其概率和码字如下：

x	1	2	3	4
$p(x)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$
$C(x)$	0	10	110	111

四个码长分别为 1, 2, 3, 3，所以

$$L(C) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = \underline{\frac{7}{4}} \text{ 比特}.$$

这里每个符号都满足 $\ell(x) = -\log_2 p(x)$ ，因此

$$H(X) = \sum_x p(x) \log_2 \frac{1}{p(x)} = \underline{\frac{7}{4}} \text{ 比特} = L(C).$$

Your turn. 为什么这个例子中的 $L(C) = H(X)$ 不需要特殊的平均技巧? 这个等式对每一项都成立: 每个码长都满足 $\ell(x) = -\log_2 p(x)$ 。两边乘以 $p(x)$ 后求和, 立即得到 $L(C) = H(X)$ 。

三个层次的可译性

定义 1.4 (非奇异码). 若不同信源符号具有不同码字, 则称编码 C 为**非奇异码**:

$$x \neq x' \implies C(x) \neq C(x').$$

等价地说, C 是一个 单射。

非奇异性只保护单个符号。为了编码符号序列, 将 C 按照拼接方式扩展为

$$C^* : \mathcal{X}^* \longrightarrow \mathcal{D}^*, \quad C^*(x_1 x_2 \cdots x_n) = C(x_1)C(x_2) \cdots C(x_n).$$

定义 1.5 (唯一可译码). 若扩展码 C^* 是非奇异的, 则称 C 为**唯一可译码**。换言之, 每个编码后的字符串至多对应一个产生它的信源序列。

定义 1.6 (前缀码). 若任何码字都不是另一不同码字的前缀, 则称该编码为**前缀码**, 也称即时码。

每个前缀码都是唯一可译码, 每个唯一可译码都是非奇异码:

$$\{\text{前缀码}\} \subset \{\text{唯一可译码}\} \subset \{\text{非奇异码}\}.$$

反方向一般不成立。

例 1.7 (唯一可译但不是前缀码). 对 $\mathcal{X} = \{A, B, C, D\}$, 考虑

$$C(A) = 0, \quad C(B) = 01, \quad C(C) = 011, \quad C(D) = 111.$$

它不是前缀码, 因为 0 是 01 和 011 的前缀; 但它仍是唯一可译码。从较长码字中删去开头的 0, 只会留下 1 或 11; 再将这些后缀与 111 比较, 只会使 $1 \leftrightarrow 11$ 来回转换, 永远不会得到空后缀。因此不会有两个信源序列产生相同的拼接结果。

Your turn. 编码 $\{0, 01, 10\}$ 是非奇异码, 却不是唯一可译码。请给出两个编码结果相同的不同信源序列。 AC 与 BA 都编码为 010。

? 为什么非奇异性不能保证拼接之后仍可译?

■ 2 KRAFT--MCMILLAN: 码长何时装得下

□□□□ 可译码在码树中占用的空间总量是有限的。

Kraft 和式把一系列码长变成一个容量检验：唯一可译性迫使这个和不超过一；反过来，任何通过检验的整数码长列表都能被装入一棵前缀码树。

何时使用： 在尝试画出码字之前先做这个检验：不可能的码长列表会立刻失败。

两个方向

方向 含义

必要性 唯一可译码 $\implies \sum_x D^{-\ell(x)} \leq 1$

充分性 满足 $\sum_x D^{-\ell(x)} \leq 1$ 的整数码长 $\implies$ 存在具有这些码长的前缀码

定理 2.1 (Kraft-McMillan 不等式). 设 $C : \mathcal{X} \rightarrow \mathcal{D}^*$ 是一个 D 元唯一可译码，并记 $\ell_x = |C(x)|$ 。则

$$\sum_{x \in \mathcal{X}} D^{-\ell_x} \leq 1.$$

反过来，若正整数列 $(\ell_x)_{x \in \mathcal{X}}$ 满足这个不等式，则存在一个 D 元前缀码 C ，使得每个 $x \in \mathcal{X}$ 都满足 $|C(x)| = \ell_x$ 。

必要性： 拼接 n 个符号来放大约束

必要性. 记

$$K = \sum_{x \in \mathcal{X}} D^{-\ell_x}, \quad \ell_{\min} = \min_x \ell_x, \quad \ell_{\max} = \max_x \ell_x.$$

对信源字符串 $x^n = (x_1, \dots, x_n)$ ，编码后的总长度为 $\ell(x^n) = \sum_{i=1}^n \ell_{x_i}$ 。展开 n 次方可得

$$K^n = \sum_{x^n \in \mathcal{X}^n} D^{-\ell(x^n)} = \sum_{k=n\ell_{\min}}^{n\ell_{\max}} A_k D^{-k},$$

其中 A_k 表示编码后总长度为 k 的 $\mathcal{X}^n$ 中信源字符串的数量。

唯一可译性保证这 A_k 个输出字符串彼此不同，而 $\mathcal{D}$ 上长度为 k 的字符串总共只有 D^k 个，所以 $A_k \leq D^k$ 。因此

$$K^n \leq \sum_{k=n\ell_{\min}}^{n\ell_{\max}} 1 = n(\ell_{\max} - \ell_{\min}) + 1.$$

两边取 n 次方根，再令 $n \rightarrow \infty$ ，得到 $K \leq 1$ 。 ■

Your turn. 证明中的哪一步真正使用了唯一可译性？唯一可译性把信源字符串计数转成了输出字符串计数：不同信源字符串必须产生不同的编码字符串，所以在总共 D^k 个长度为 k 的字符串中，至多能出现 $A_k \leq D^k$ 个编码结果。

充分性： 依次装入相邻的 D 进制区间

充分性. 重新标记 $\mathcal{X} = \{1, \dots, M\}$, 使得 $\ell_1 \leq \ell_2 \leq \dots \leq \ell_M$, 并定义

$$r_m = \sum_{i=1}^{m-1} D^{-\ell_i}, \quad 1 \leq m \leq M.$$

Kraft 不等式给出 $0 \leq r_m < 1$ 。由于对 $i < m$ 有 $\ell_i \leq \ell_m$, $D^{\ell_m} r_m$ 是整数, 所以 r_m 具有一个至多含 ℓ_m 位的有限 D 进制展开。令 $C(m)$ 为其前 ℓ_m 位, 不足处补零。

为了验证所得编码是前缀码, 取 $m < n$ 。由构造,

$$r_n - r_m = \sum_{i=m}^{n-1} D^{-\ell_i} \geq D^{-\ell_m}.$$

另一方面, 所有以 $C(m)$ 这 ℓ_m 位开头的 D 进制小数都落在半开区间 $[r_m, r_m + D^{-\ell_m})$ 中。因此 r_n 不可能以 $C(m)$ 开头, 也就是说 $C(m)$ 不是 $C(n)$ 的前缀。故 C 是一个具有指定码长的前缀码。■

例 2.2 (恰好填满的二进制编码). 对码长 $(1, 2, 3, 3)$,

$$2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = 1.$$

上述构造取区间左端点 $0, \frac{1}{2}, \frac{3}{4}, \frac{7}{8}$, 它们的二进制展开给出前缀码 $0, 10, 110, 111$ 。

Your turn. 二进制唯一可译码能否具有码长 $(1, 2, 2)$? 计算 Kraft 和式并作出判断。

$$2^{-1} + 2^{-2} + 2^{-2} = \underline{1}.$$

可以。Kraft 和式等于 1, 因此逆命题保证存在前缀码; 例如 $0, 10, 11$ 。

? 为什么取 n 次方根的极限会迫使 Kraft 和式不超过一?

■ 3 AEP 与典型序列

□□□□ 长随机分组的表现仿佛只有一批近似等概率的结果。

渐近等分性质把熵变成一幅几何图景：几乎全部概率都落在约 $2^{nH(X)}$ 个长度为 n 的序列上，而其中每个序列的概率约为 $2^{-nH(X)}$ 。

何时使用： 当需要把单符号分布转化成长分组结论时，使用典型集。

Bernoulli 预览

例 3.1 (数零与一). 设 $X \sim \text{Bernoulli}(p)$ ，且 $X_1, \dots, X_n$ 是它的 i.i.d. 副本。若实现值 $x^n = (x_1, \dots, x_n)$ 含有 $N_1(x^n)$ 个一，则

$$p_{X^n}(x^n) = p^{N_1(x^n)}(1-p)^{n-N_1(x^n)}.$$

大数定律给出 $N_1(X^n)/n \rightarrow p$ (依概率)。因此对大多数长序列，

$$\begin{aligned} -\frac{1}{n} \log p_{X^n}(X^n) &\approx -p \log p - (1-p) \log(1-p) \\ &= \underline{H(X)}. \end{aligned}$$

等价地，一个典型实现值的概率约为 $2^{-nH(X)}$ 。

随机变量收敛的三种方式

定义 3.2 (依概率收敛). 设 $Y_1, Y_2, \dots$ 与 Y 是同一概率空间上的实值随机变量。若对每个 $\epsilon > 0$ 都有

$$P(|Y_n - Y| > \epsilon) \rightarrow \underline{0} \quad (n \rightarrow \infty),$$

则称 Y_n **依概率收敛** 于 Y ，记作 $Y_n \xrightarrow{P} Y$ 。因此，依概率收敛控制的是“出现固定大小误差的概率”；它并不声称每条样本路径最终都一直靠近极限。

定义 3.3 (均方收敛). 设 $Y_1, Y_2, \dots$ 与 Y 都平方可积。若

$$E[|Y_n - Y|^2] \rightarrow 0,$$

则称 Y_n **均方收敛** 于 Y ，也称在 L^2 中收敛，记作 $Y_n \xrightarrow{L^2} Y$ 。它要求平均平方误差趋于零，而不只是较大误差出现的概率趋于零。

定义 3.4 (以概率 1 收敛). 若

$$\mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} Y_n(\omega) = Y(\omega)\right\}\right) = 1,$$

则称 Y_n **以概率 1 收敛** 于 Y , 也称几乎必然收敛, 记作 $Y_n \xrightarrow{\text{a.s.}} Y$ 。也就是说, 除去同一个零概率例外集合后, 对其余每条样本路径, 数列 $Y_n(\omega)$ 都收敛到 $Y(\omega)$ 。

最常用的蕴含关系是

$$Y_n \xrightarrow{L^2} Y \implies Y_n \xrightarrow{\text{P}} Y, \quad Y_n \xrightarrow{\text{a.s.}} Y \implies Y_n \xrightarrow{\text{P}} Y.$$

第一个蕴含来自 $\mathbb{P}(|Y_n - Y| > \epsilon) \leq \mathbb{E}[|Y_n - Y|^2]/\epsilon^2$ 。一般而言, 若没有额外条件, 均方收敛与几乎必然收敛互不蕴含。

在 AEP 中, $Y_n = -n^{-1} \log p_{X^n}(X_1, \dots, X_n)$, 而极限 $Y = H(X)$ 是常数; 定理所断言的是依概率收敛。

定理 3.5 (弱渐近等分性质). 设 X 是有限字母表上的离散随机变量, $X_1, X_2, \dots$ 是 X 的 i.i.d. 副本。则

$$-\frac{1}{n} \log p_{X^n}(X_1, \dots, X_n) \rightarrow H(X) \quad (\text{依概率}).$$

证明. 在 X 的支撑上定义 $Z_i = -\log p_X(X_i)$ 。由独立性,

$$-\log p_{X^n}(X_1, \dots, X_n) = \sum_{i=1}^n -\log p_X(X_i) = \sum_{i=1}^n Z_i.$$

随机变量 Z_i 独立同分布, 并且

$$\mathbb{E}[Z_i] = \sum_x p_X(x) \log \frac{1}{p_X(x)} = H(X).$$

对 $n^{-1} \sum_i Z_i$ 使用弱大数定律即得结论。 ■

Your turn. AEP 证明中, 大数定律作用于哪个单符号随机变量? 对 surprise $Z = -\log p_X(X)$ 使用大数定律; 它的期望恰好是 $H(X)$ 。

弱典型性: 精确定义“近似”

定义 3.6 (弱典型集). 对 $\epsilon > 0$, 长度为 n 的弱典型集定义为

$$T_{n,\epsilon} = \left\{x^n \in \mathcal{X}^n : \left| -\frac{1}{n} \log p_{X^n}(x^n) - H(X) \right| \leq \underline{\epsilon} \right\}.$$

其中的元素称为长度为 n 的 ϵ -典型序列。

定理 3.7 (典型集的性质). 对每个 $\epsilon > 0$, 当 n 充分大时:

1. 每个 $x^n \in T_{n,\epsilon}$ 都满足

$$2^{-n(H(X)+\epsilon)} \leq p_{X^n}(x^n) \leq 2^{-n(H(X)-\epsilon)};$$

2. $P(X^n \in T_{n,\epsilon}) > 1 - \epsilon$;

3. 集合大小满足

$$(1 - \epsilon)2^{n(H(X)-\epsilon)} < |T_{n,\epsilon}| \leq 2^{n(H(X)+\epsilon)}.$$

第一条对每个 n 都直接来自定义; 只有后两条需要 n 充分大。

证明. 对定义中的不等式取指数便得到第一条。AEP 给出

$$P(X^n \notin T_{n,\epsilon}) = P\left(\left| -\frac{1}{n} \log p_{X^n}(X^n) - H(X) \right| > \epsilon\right) \rightarrow 0,$$

从而得到第二条。

为证明基数上界, 对每个典型序列使用概率下界:

$$1 \geq \sum_{x^n \in T_{n,\epsilon}} p_{X^n}(x^n) \geq |T_{n,\epsilon}| 2^{-n(H(X)+\epsilon)}.$$

为证明基数下界, 把概率上界与总质量估计结合:

$$1 - \epsilon < \sum_{x^n \in T_{n,\epsilon}} p_{X^n}(x^n) \leq |T_{n,\epsilon}| 2^{-n(H(X)-\epsilon)}.$$

整理两个不等式即可得到所述界。

Your turn. 结合概率界与基数界, 补全 AEP 口号: 约有 $2^{nH(X)}$ 个典型序列, 每个序列的概率约为 $2^{-nH(X)}$ 。

承载几乎全部质量的最小集合

定义 3.8 (最小高概率集合). 对 $0 < \delta < 1$, 令 $S_m^\delta \subseteq \mathcal{X}^m$ 是满足

$$P(X^m \in S_m^\delta) \geq 1 - \delta$$

且具有 最小基数 的集合。这对应手写稿中的“强”观点: 只保留为承载指定概率质量所必需的最高概率序列。

命题 3.9 (两种典型集的指数等价性). 设 (δ_j) 是任意满足 $\delta_j > 0$ 且 $\delta_j \rightarrow 0$ 的序列。则

$$\lim_{j \rightarrow \infty} \limsup_{m \rightarrow \infty} \left| \frac{1}{m} \log \frac{|S_m^{\delta_j}|}{|T_{m,\delta_j}|} \right| = 0.$$

因此, 当容差趋于零时, 最小高概率集合与弱典型集虽然可能包含不同的具体序列,

但它们在指数尺度上的大小相同。

证明. 对每个固定的 $0 < \delta < 1$, AEP 与典型集的界给出

$$\lim_{m \rightarrow \infty} \frac{1}{m} \log |S_m^\delta| = H(X), \quad H(X) - \delta \leq \liminf_m \frac{1}{m} \log |T_{m,\delta}| \leq \limsup_m \frac{1}{m} \log |T_{m,\delta}| \leq H(X) + \delta.$$

第一个极限的上界可通过选取典型集得到；下界则把任意质量至少为 $1 - \delta$ 的集合与一个 η -典型集相交，再令 $\eta \downarrow 0$ 得到。因此，基数比的归一化对数之绝对值的上极限至多为 δ 。代入 $\delta = \delta_j$ 并令 $j \rightarrow \infty$ 即证。 ■

?“每个典型序列的概率”与“典型序列的数量”如何相乘回到一？