




信息论

第二讲 · 从码字到典型序列

Oxford B8.4 · 2024--25

fanzuituanhuo

August 18, 2026

dyed in indigo, madder & weld; ruled in iron-gall. woven on LOOM.

一条主线与知识地图

□□□□□

信源编码把每个信源符号替换成一个有限字符串。编码质量有两个侧面：以期望码长衡量的**效率**，以及在码字拼接后检验的**可译性**。Kraft-McMillan 控制哪些码长能够装下；AEP 则说明为什么熵是长 i.i.d. 分组编码的自然尺度。

目前的知识地图

站	对象	要回答的问题
1	$C : \mathcal{X} \rightarrow \mathcal{D}^*$	每个信源符号由哪个有限字符串表示？
2	$L(C) = \mathbb{E}[C(X)]$	平均要使用多少个编码符号？
3	$C^* : \mathcal{X}^* \rightarrow \mathcal{D}^*$	码字拼接起来以后还能否唯一解码？
4	$\sum_x D^{-l_x} \leq 1$	哪些码长列表能够对应可译码？
5	$-n^{-1} \log p(X^n) \rightarrow H(X)$	长分组的概率质量集中在哪里？
6	$H_D(X) \leq L(C) < H_D(X) + 1$	唯一可译码最短能做到多短？
7	$n^{-1} \mathbb{E}[C(X^n)] \rightarrow H(X)$	对整个分组编码换来了什么？
8	$-n^{-1} \log p(X^n) \rightarrow \bar{H}$	信源不是 i.i.d. 时还剩下什么？
9	$H_D(X) + D_D(p\ q)$	显式的码要付多少代价？按错误分布设计又如何？

全文约定

信源字母表 $\mathcal{X}$ 有限， $\mathcal{D}^*$ 表示由 D 元编码字母表 $\mathcal{D}$ 中的符号组成的所有有限长字符串。例子通常取 $\mathcal{D} = \{0, 1\}$ 。

目录

一条主线与知识地图	1
第二讲 · 信源编码	3
1 编码、码长与可译性	3
2 Kraft-McMillan: 码长何时装得下	5
3 AEP 与典型序列	7
4 最优码与信源编码定理	11
5 分组码与 Shannon 信源编码定理	14
6 两个显式构造: Shannon 码与 Fano 码	17

第二讲 · 信源编码

先给信源符号分配字符串，再按照信源分布计算平均长度，最后提出决定性问题：拼接操作是否保留了足够的结构，使我们能够逆转编码过程？对于长 i.i.d. 分组，再找出承载几乎全部概率的典型序列，从而看见熵就是序列数量的指数增长率。

1 编码、码长与可译性

□□□□ 一个码字标记一个符号；扩展码还必须保住整个符号序列。

编码从一个“信源符号到有限字符串”的映射开始。短字符串能够节省空间，但不同的符号，乃至不同的信源序列，都必须保持可区分。因此，期望码长与可译性必须放在一起研究。

从信源符号到码字

定义 1.1 (信源编码). 设随机变量 X 的有限字母表为 $\mathcal{X}$ 。一个 D 元信源编码是映射

$$C : \mathcal{X} \rightarrow \mathcal{D}^*,$$

其中 $\mathcal{D}^*$ 是 D 元字母表 $\mathcal{D}$ 上所有 有限长字符串 的集合。字符串 $C(x)$ 称为 x 的码字， $|C(x)|$ 是它的码长。

例如，若 $\mathcal{X} = \{\text{红}, \text{蓝}\}$ 且 $\mathcal{D} = \{0, 1\}$ ，可以取 $C(\text{红}) = 00$ 、 $C(\text{蓝}) = 11$ 。

定义 1.2 (期望码长). 若 X 的概率质量函数为 p ，编码 C 的期望码长定义为

$$L(C) = \mathbb{E}[|C(X)|] = \sum_{x \in \mathcal{X}} p(x) |C(x)|.$$

例 1.3 (与熵匹配的二进制编码). 令 $\mathcal{X} = \{1, 2, 3, 4\}$ ，其概率和码字如下：

x	1	2	3	4
$p(x)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$
$C(x)$	0	10	110	111

四个码长分别为 1, 2, 3, 3，所以

$$L(C) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = \underline{\frac{7}{4}} \text{ 比特}.$$

这里每个符号都满足 $|C(x)| = -\log_2 p(x)$ ，因此

$$H(X) = \sum_x p(x) \log_2 \frac{1}{p(x)} = \underline{\frac{7}{4}} \text{ 比特} = L(C).$$

Your turn. 为什么这个例子中的 $L(C) = H(X)$ 不需要特殊的平均技巧? 这个等式对每一项都成立: 每个码长都满足 $|C(x)| = -\log_2 p(x)$ 。两边乘以 $p(x)$ 后求和, 立即得到 $L(C) = H(X)$ 。

三个层次的可译性

定义 1.4 (非奇异码). 若不同信源符号具有不同码字, 则称编码 C 为**非奇异码**:

$$x \neq x' \implies C(x) \neq C(x').$$

等价地说, C 是一个 单射。

非奇异性只保护单个符号。为了编码符号序列, 将 C 按照拼接方式扩展为

$$C^* : \mathcal{X}^* \longrightarrow \mathcal{D}^*, \quad C^*(x_1 x_2 \cdots x_n) = C(x_1)C(x_2) \cdots C(x_n).$$

定义 1.5 (唯一可译码). 若扩展码 C^* 是非奇异的, 则称 C 为**唯一可译码**。换言之, 每个编码后的字符串至多对应一个产生它的信源序列。

定义 1.6 (前缀码). 若任何码字都不是另一不同码字的前缀, 则称该编码为**前缀码**, 也称**即时码**。

每个前缀码都是唯一可译码, 每个唯一可译码都是非奇异码:

$$\{\text{前缀码}\} \subset \{\text{唯一可译码}\} \subset \{\text{非奇异码}\}.$$

反方向一般不成立。

例 1.7 (唯一可译但不是前缀码). 对 $\mathcal{X} = \{A, B, C, D\}$, 考虑

$$C(A) = 0, \quad C(B) = 01, \quad C(C) = 011, \quad C(D) = 111.$$

它不是前缀码, 因为 0 是 01 和 011 的前缀; 但它仍是唯一可译码。从较长码字中删去开头的 0, 只会留下 1 或 11; 再将这些后缀与 111 比较, 只会使 $1 \leftrightarrow 11$ 来回转换, 永远不会得到空后缀。因此不会有两个信源序列产生相同的拼接结果。

Your turn. 编码 $\{0, 01, 10\}$ 是非奇异码, 却不是唯一可译码。请给出两个编码结果相同的不同信源序列。**AC 与 BA 都编码为 010。**

? 为什么非奇异性不能保证拼接之后仍可译?

■ 2 KRAFT--MCMILLAN: 码长何时装得下

□□□□ 可译码在码树中占用的空间总量是有限的。

Kraft 和式把一系列码长变成一个容量检验：唯一可译性迫使这个和不超过一；反过来，任何通过检验的整数码长列表都能被装入一棵前缀码树。

何时使用： 在尝试画出码字之前先做这个检验：不可能的码长列表会立刻失败。

两个方向

方向 含义

必要性 唯一可译码 $\implies \sum_x D^{-\ell_x} \leq 1$

充分性 满足 $\sum_x D^{-\ell_x} \leq 1$ 的整数码长 $\implies$ 存在具有这些码长的前缀码

定理 2.1 (Kraft–McMillan 不等式). 设 $C : \mathcal{X} \rightarrow \mathcal{D}^*$ 是一个 D 元唯一可译码，并记 $\ell_x = |C(x)|$ 。则

$$\sum_{x \in \mathcal{X}} D^{-\ell_x} \leq 1.$$

反过来，若正整数列 $(\ell_x)_{x \in \mathcal{X}}$ 满足这个不等式，则存在一个 D 元前缀码 C ，使得每个 $x \in \mathcal{X}$ 都满足 $|C(x)| = \ell_x$ 。

必要性： 拼接 n 个符号来放大约束

必要性. 记

$$K = \sum_{x \in \mathcal{X}} D^{-\ell_x}, \quad \ell_{\min} = \min_x \ell_x, \quad \ell_{\max} = \max_x \ell_x.$$

对信源字符串 $x^n = (x_1, \dots, x_n)$ ，编码后的总长度为 $|C^*(x^n)| = \sum_{i=1}^n \ell_{x_i}$ 。展开 n 次方可得

$$K^n = \sum_{x^n \in \mathcal{X}^n} D^{-|C^*(x^n)|} = \sum_{k=n\ell_{\min}}^{n\ell_{\max}} A_k D^{-k},$$

其中 A_k 表示编码后总长度为 k 的 $\mathcal{X}^n$ 中信源字符串的数量。

唯一可译性保证这 A_k 个输出字符串彼此不同，而 $\mathcal{D}$ 上长度为 k 的字符串总共只有 D^k 个，所以 $A_k \leq D^k$ 。因此

$$K^n \leq \sum_{k=n\ell_{\min}}^{n\ell_{\max}} 1 = n(\ell_{\max} - \ell_{\min}) + 1.$$

两边取 n 次方根，再令 $n \rightarrow \infty$ ，得到 $K \leq 1$ 。 ■

Your turn. 证明中的哪一步真正使用了唯一可译性？唯一可译性把信源字符串计数转成了输出字符串计数：不同信源字符串必须产生不同的编码字符串，所以在总共 D^k 个长度为 k 的字符串中，至多能出现 $A_k \leq D^k$ 个编码结果。

充分性： 依次装入相邻的 D 进制区间

充分性. 重新标记 $\mathcal{X} = \{1, \dots, M\}$, 使得 $\ell_1 \leq \ell_2 \leq \dots \leq \ell_M$, 并定义

$$r_m = \sum_{i=1}^{m-1} D^{-\ell_i}, \quad 1 \leq m \leq M.$$

Kraft 不等式给出 $0 \leq r_m < 1$ 。由于对 $i < m$ 有 $\ell_i \leq \ell_m$, $D^{\ell_m} r_m$ 是整数, 所以 r_m 具有一个至多含 ℓ_m 位的有限 D 进制展开。令 $C(m)$ 为其前 ℓ_m 位, 不足处补零。

为了验证所得编码是前缀码, 取 $m < n$ 。由构造,

$$r_n - r_m = \sum_{i=m}^{n-1} D^{-\ell_i} \geq D^{-\ell_m}.$$

另一方面, 所有以 $C(m)$ 这 ℓ_m 位开头的 D 进制小数都落在半开区间 $[r_m, r_m + D^{-\ell_m})$ 中。因此 r_n 不可能以 $C(m)$ 开头, 也就是说 $C(m)$ 不是 $C(n)$ 的前缀。故 C 是一个具有指定码长的前缀码。■

例 2.2 (恰好填满的二进制编码). 对码长 $(1, 2, 3, 3)$,

$$2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = 1.$$

上述构造取区间左端点 $0, \frac{1}{2}, \frac{3}{4}, \frac{7}{8}$, 它们的二进制展开给出前缀码 $0, 10, 110, 111$ 。

Your turn. 二进制唯一可译码能否具有码长 $(1, 2, 2)$? 计算 Kraft 和式并作出判断。

$$2^{-1} + 2^{-2} + 2^{-2} = \underline{1}.$$

可以。Kraft 和式等于 1, 因此逆命题保证存在前缀码; 例如 $0, 10, 11$ 。

? 为什么取 n 次方根的极限会迫使 Kraft 和式不超过一?

■ 3 AEP 与典型序列

□□□□ 长随机分组的表现仿佛只有一批近似等概率的结果。

渐近等分性质把熵变成一幅几何图景：几乎全部概率都落在约 $2^{nH(X)}$ 个长度为 n 的序列上，而其中每个序列的概率约为 $2^{-nH(X)}$ 。

何时使用： 当需要把单符号分布转化成长分组结论时，使用典型集。

Bernoulli 预览

例 3.1 (数零与一). 设 $X \sim \text{Bernoulli}(p)$ ，且 $X_1, \dots, X_n$ 是它的 i.i.d. 副本。若实现值 $x^n = (x_1, \dots, x_n)$ 含有 $N_1(x^n)$ 个一，则

$$p_{X^n}(x^n) = p^{N_1(x^n)}(1-p)^{n-N_1(x^n)}.$$

弱大数定律给出 $N_1(X^n)/n \rightarrow p$ (依概率)。因此对大多数长序列，

$$\begin{aligned} -\frac{1}{n} \log p_{X^n}(X^n) &\approx -p \log p - (1-p) \log(1-p) \\ &= \underline{H(X)}. \end{aligned}$$

等价地，一个典型实现值的概率约为 $2^{-nH(X)}$ 。

随机变量收敛的三种方式

定义 3.2 (依概率收敛). 设 $Y_1, Y_2, \dots$ 与 Y 是同一概率空间上的实值随机变量。若对每个 $\epsilon > 0$ 都有

$$\mathbb{P}(|Y_n - Y| > \epsilon) \rightarrow \underline{0} \quad (n \rightarrow \infty),$$

则称 Y_n **依概率收敛** 于 Y ，记作 $Y_n \xrightarrow{P} Y$ 。因此，依概率收敛控制的是“出现固定大小误差的概率”；它并不声称每条样本路径最终都一直靠近极限。

定义 3.3 (均方收敛). 设 $Y_1, Y_2, \dots$ 与 Y 都平方可积。若

$$\mathbb{E}[|Y_n - Y|^2] \rightarrow 0,$$

则称 Y_n **均方收敛** 于 Y ，也称在 L^2 中收敛，记作 $Y_n \xrightarrow{L^2} Y$ 。它要求平均平方误差趋于零，而不只是较大误差出现的概率趋于零。

定义 3.4 (以概率 1 收敛). 若

$$\mathbb{P}\left(\left\{\omega : \lim_{n \rightarrow \infty} Y_n(\omega) = Y(\omega)\right\}\right) = 1,$$

则称 Y_n **以概率 1 收敛** 于 Y , 也称几乎必然收敛, 记作 $Y_n \xrightarrow{\text{a.s.}} Y$. 也就是说, 除去同一个零概率例外集合后, 对其余每条样本路径, 数列 $Y_n(\omega)$ 都收敛到 $Y(\omega)$.

最常用的蕴含关系是

$$Y_n \xrightarrow{L^2} Y \implies Y_n \xrightarrow{P} Y, \quad Y_n \xrightarrow{\text{a.s.}} Y \implies Y_n \xrightarrow{P} Y.$$

第一个蕴含来自 $\mathbb{P}(|Y_n - Y| > \epsilon) \leq \mathbb{E}[|Y_n - Y|^2]/\epsilon^2$. 一般而言, 若没有额外条件, 均方收敛与几乎必然收敛互不蕴含。(对 AEP 的 i.i.d. 变量而言两者其实都成立: 方差有限给出 L^2 收敛, 强大数定律给出几乎必然收敛; 依概率收敛是三者中最弱的, 也恰是弱典型性所需。)

弱大数定律

定理 3.5 (弱大数定律). 设 $Y_1, Y_2, \dots$ 独立同分布, 均值 $\mu = \mathbb{E}[Y_1]$ 与方差都有限。则

$$\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{P} \mu.$$

在 AEP 中, $Y_n = -n^{-1} \log p_{X^n}(X_1, \dots, X_n)$, 而极限 $Y = H(X)$ 是常数; 定理所断言的是依概率收敛。

定理 3.6 (弱渐近等分性质). 设 X 是有限字母表上的离散随机变量, $X_1, X_2, \dots$ 是 X 的 i.i.d. 副本。则

$$-\frac{1}{n} \log p_{X^n}(X_1, \dots, X_n) \longrightarrow H(X) \quad (\text{依概率}).$$

证明. 在 X 的支撑上定义 $Z_i = -\log p_X(X_i)$ 。由独立性,

$$-\log p_{X^n}(X_1, \dots, X_n) = \sum_{i=1}^n -\log p_X(X_i) = \sum_{i=1}^n Z_i.$$

随机变量 Z_i 独立同分布, 并且

$$\mathbb{E}[Z_i] = \sum_x p_X(x) \log \frac{1}{p_X(x)} = H(X).$$

对 $n^{-1} \sum_i Z_i$ 使用弱大数定律即得结论。 ■

Your turn. AEP 证明中, 大数定律作用于哪个单符号随机变量? 对 surprise $Z = -\log p_X(X)$ 使用大数定律; 它的期望恰好是 $H(X)$ 。

弱典型性: 精确定义“近似”

定义 3.7 (弱典型集). 对 $\epsilon > 0$, 长度为 n 的弱典型集定义为

$$T_{n,\epsilon} = \left\{ x^n \in \mathcal{X}^n : \left| -\frac{1}{n} \log p_{X^n}(x^n) - H(X) \right| \leq \underline{\epsilon} \right\}.$$

其中的元素称为长度为 n 的 ϵ -典型序列。

定理 3.8 (典型集的性质). 对每个 $\epsilon > 0$, 当 n 充分大时:

1. 每个 $x^n \in T_{n,\epsilon}$ 都满足

$$2^{-n(H(X)+\epsilon)} \leq p_{X^n}(x^n) \leq 2^{-n(H(X)-\epsilon)};$$

2. $\mathbb{P}(X^n \in T_{n,\epsilon}) > 1 - \epsilon$;

3. 集合大小满足

$$(1 - \epsilon)2^{n(H(X)-\epsilon)} < |T_{n,\epsilon}| \leq 2^{n(H(X)+\epsilon)}.$$

第一条对每个 n 都直接来自定义; 只有后两条需要 n 充分大。

证明. 对定义中的不等式取指数便得到第一条。AEP 给出

$$\mathbb{P}(X^n \notin T_{n,\epsilon}) = \mathbb{P}\left(\left| -\frac{1}{n} \log p_{X^n}(X^n) - H(X) \right| > \epsilon\right) \rightarrow 0,$$

从而得到第二条。

为证明基数上界, 对每个典型序列使用概率下界:

$$1 \geq \sum_{x^n \in T_{n,\epsilon}} p_{X^n}(x^n) \geq |T_{n,\epsilon}| 2^{-n(H(X)+\epsilon)}.$$

为证明基数下界, 把概率上界与总质量估计结合:

$$1 - \epsilon < \sum_{x^n \in T_{n,\epsilon}} p_{X^n}(x^n) \leq |T_{n,\epsilon}| 2^{-n(H(X)-\epsilon)}.$$

整理两个不等式即可得到所述界。 ■

Your turn. 结合概率界与基数界, 补全 AEP 口号: 约有 $\underline{2^{nH(X)}}$ 个典型序列, 每个序列的概率约为 $\underline{2^{-nH(X)}}$ 。

承载几乎全部质量的最小集合

定义 3.9 (最小高概率集合). 对 $0 < \delta < 1$, 令 $S_m^\delta \subseteq \mathcal{X}^m$ 是满足

$$\mathbb{P}(X^m \in S_m^\delta) \geq 1 - \delta$$

且具有 最小基数 的集合。这对应手稿中的“强”观点: 只保留为承载指定概率质量所必需的最高概率序列。

命题 3.10 (两种典型集的指数等价性). 设 (δ_j) 是任意满足 $\delta_j > 0$ 且 $\delta_j \rightarrow 0$ 的序列。则

$$\lim_{j \rightarrow \infty} \limsup_{m \rightarrow \infty} \left| \frac{1}{m} \log \frac{|S_m^{\delta_j}|}{|T_{m, \delta_j}|} \right| = 0.$$

因此，当容差趋于零时，最小高概率集合与弱典型集虽然可能包含不同的具体序列，但它们在指数尺度上的大小相同。

证明. 对每个固定的 $0 < \delta < 1$ ，AEP 与典型集的界给出

$$\lim_{m \rightarrow \infty} \frac{1}{m} \log |S_m^\delta| = H(X), \quad H(X) - \delta \leq \liminf_m \frac{1}{m} \log |T_{m, \delta}| \leq \limsup_m \frac{1}{m} \log |T_{m, \delta}| \leq H(X) + \delta.$$

第一个极限的上界可通过选取典型集得到；下界则把任意质量至少为 $1 - \delta$ 的集合与一个 η -典型集相交，再令 $\eta \downarrow 0$ 得到。因此，基数比的归一化对数之绝对值的上极限至多为 δ 。代入 $\delta = \delta_j$ 并令 $j \rightarrow \infty$ 即证。 ■

?“每个典型序列的概率”与“典型序列的数量”如何相乘回到一？

■ 4 最优码与信源编码定理

□□□□ Kraft-McMillan 把「找最好的码」变成一个约束极小化问题，其解正是 $-\log_D p(x)$ 。

熵是期望码长的普遍下界；Shannon 码与这个下界相差不到一个 D 元符号。

何时使用： 当需要把某个码的期望长度与信息论下界作比较时，就用这一节。

什么叫「最优」

定义 4.1 (最优码). 设随机变量 X 的 pmf 为 p 。符号码 $C: \mathcal{X} \rightarrow \mathcal{D}^*$ 称为对 X **最优**，如果它在所有 唯一可译 的码 $C': \mathcal{X} \rightarrow \mathcal{D}^*$ 中最小化 $E[|C(X)|]$ 。

比较的范围是唯一可译码而不是前缀码；由 Kraft-McMillan，这两类码可实现的码长列表完全相同，所以只在前缀码里寻找最优解不会有任何损失。

定义背后的优化问题

记 $\ell_x = |C(x)|$ 。Kraft-McMillan 说：一系列码长能被某个唯一可译码实现，当且仅当它通过 Kraft 检验。于是最优性就是约束优化问题

$$\text{最小化 } \sum_{x \in \mathcal{X}} p(x) \ell_x \quad \text{约束} \quad \sum_{x: p(x) > 0} D^{-\ell_x} \leq 1, \quad \ell_x \in \mathbb{N}.$$

用 Lagrange 乘子求松弛解

忽略整数约束，把 ℓ_x 当作实数，并把 Kraft 约束取成等号。Lagrange 函数为

$$J(\ell, \lambda) = \sum_x p(x) \ell_x - \lambda \left(\sum_x D^{-\ell_x} - 1 \right).$$

令 $\partial J / \partial \ell_x = 0$ 得 $p(x) + \lambda D^{-\ell_x} \ln D = 0$ ，即 $D^{-\ell_x} = -p(x) / (\lambda \ln D)$ 。对 x 求和并代入约束 $\sum_x D^{-\ell_x} = 1$ ，迫使 $-\lambda \ln D = 1$ ，因此

$$D^{-\ell_x} = p(x), \quad \ell_x = \underline{-\log_D p(x)}.$$

目标函数关于 ℓ 是凸的，约束集也是凸的，所以这个驻点确实是极小点。它对应的平均长度为

$$E[|C(X)|] = \sum_x -p(x) \log_D p(x) = H_D(X).$$

这里 $H_D(X) = \sum_x p(x) \log_D \frac{1}{p(x)} = H(X) / \log_2 D$ 是以 D 元单位度量的熵； $D = 2$ 时就是以比特为单位的通常的熵。

下界就是熵

定理 4.2 (信源编码定理：逐符号版本). 设 X 在有限集 $\mathcal{X}$ 中取值， C 是一个唯一可译的 D 元信源码。则

$$H_D(X) \leq E[|C(X)|],$$

且等号成立当且仅当对每个满足 $p(x) > 0$ 的 x 都有 $-\log_D p(x) \in \mathbb{N}$ 。

证明. 令 $\ell_x = |C(x)|$, 并定义辅助分布

$$q(x) = \frac{D^{-\ell_x}}{\sum_{x'} D^{-\ell_{x'}}}, \quad c = \sum_{x'} D^{-\ell_{x'}}.$$

于是

$$\begin{aligned} \mathbb{E}[|C(X)|] - H_D(X) &= \sum_x p(x)\ell_x + \sum_x p(x)\log_D p(x) \\ &= -\sum_x p(x)\log_D(D^{-\ell_x}) + \sum_x p(x)\log_D p(x) \\ &= -\sum_x p(x)\log_D(q(x)c) + \sum_x p(x)\log_D p(x) \\ &= -\log_D c + \sum_x p(x)\log_D \frac{p(x)}{q(x)} \\ &= -\log_D c + D_D(p\|q) \geq 0. \end{aligned}$$

最后一步用到两件事: 由 Kraft-McMillan 有 $c \leq 1$, 故 $-\log_D c \geq 0$; 以及相对熵非负。等号要求两项同时为零, 即 $c = 1$ 且 $p = q$, 这恰好是 $D^{-\ell_x} = p(x)$, 也就是 $\ell_x = -\log_D p(x) \in \mathbb{N}$ 。■

Your turn. 证明把差值 $\mathbb{E}[|C(X)|] - H_D(X)$ 拆成了两个非负项。分别说出它们是什么, 以及各自非负的依据。一项是松弛量 $-\log_D c$, 其中 $c = \sum_x D^{-\ell_x}$, 由 Kraft-McMillan 的 $c \leq 1$ 保证非负; 另一项是散度 $D_D(p\|q)$, 由 Gibbs 不等式保证非负。只有当码把码树恰好填满 ($c = 1$) 且与信源匹配 ($q = p$) 时, 差值才为零。

向上取整最多多花一个符号

命题 4.3 (Shannon 码). 设 X 如上。存在前缀码 $\bar{C}$ 满足

$$H_D(X) \leq \mathbb{E}[|\bar{C}(X)|] < H_D(X) + 1,$$

因而最优码也满足同样的上下界。

证明. 取 $\ell_x = \lceil -\log_D p(x) \rceil$ 。由于 $\ell_x \geq -\log_D p(x)$,

$$\sum_x D^{-\ell_x} \leq \sum_x D^{\log_D p(x)} = \sum_x p(x) = 1,$$

所以由 Kraft-McMillan 存在恰好具有这些码长的前缀码。由取整的定义,

$$-\log_D p(x) \leq \ell_x < -\log_D p(x) + 1.$$

以 $p(x)$ 为权对 x 求平均即得所述界。最优码不会比这个码更长, 而由定理 4.2 它也不会短于 $H_D(X)$ 。■

Your turn. 把 $-\log_D p(x)$ 换成它的上取整之后，为什么 Kraft 检验仍然通过？增大码长会减小 $D^{-\ell_x}$ ，所以 Kraft 和式只会变小：它仍不超过 $\sum_x p(x) = 1$ 。

Your turn. Shannon 码界中的「+1」来自哪里？为什么一旦对长分组编码它就无关紧要？它是强制码长取整数的代价：每个符号因取整损失不到一个编码符号。对 n 个符号一起编码时，这一次损失被摊到 n 个信源符号上，每符号超出至多 $1/n$ 。

？证明中的哪两个不等式恰好在 $L(C) = H_D(X)$ 时同时取等？

■ 5 分组码与 SHANNON 信源编码定理

□□□□ 一次编码 n 个符号，取整的损失就被所有符号分摊。

把 Shannon 码用在 n 个 i.i.d. 符号组成的分组上，熵这个下界保持不变，而「+1」的取整代价被除以 n 。让 n 增大，就说明熵率可以被任意逼近：这正是 Shannon 1948 年的信源编码定理。

何时使用： 当一个逐符号的界只差一个不会自动变小的加性常数时，就改用分组。

基本想法

考虑取值于 $\mathcal{X}^n$ 的随机变量 $(X_1, \dots, X_n)$ ，其中 $X_1, \dots, X_n$ 是 X 的 i.i.d. 副本。独立性使熵具有可加性，

$$H(X_1, \dots, X_n) = \underline{nH(X)},$$

于是把命题 4.3 用在分组变量（而不是单个符号）上，得到：当 C 是该分组的最优二元码时，

$$nH(X) \leq \mathbb{E}[|C(X_1, \dots, X_n)|] < nH(X) + 1.$$

两边除以 n ，就变成逐符号的陈述：

$$H(X) \leq \frac{1}{n} \mathbb{E}[|C(X_1, \dots, X_n)|] < H(X) + \underline{\frac{1}{n}}.$$

现在这个超出量掌握在我们手里：取 n 充分大它就消失。

Shannon 定理

定理 5.1 (信源编码定理, Shannon 1948). 设 $X_1, X_2, \dots$ 是取值于状态空间 $\mathcal{X}$ 的 i.i.d. 离散随机变量序列。对每个 $\epsilon > 0$ ，都存在 $n \in \mathbb{N}$ 和映射

$$C : \mathcal{X}^n \rightarrow \{0, 1\}^*$$

使得：

1. 诱导映射 $C^* : \bigcup_{k=0}^{\infty} \mathcal{X}^{nk} \rightarrow \{0, 1\}^*$,

$$(x_1, \dots, x_{nk}) \mapsto C(x_1, \dots, x_n) C(x_{n+1}, \dots, x_{2n}) \cdots C(x_{(k-1)n+1}, \dots, x_{nk}),$$

是单射；

2. $\frac{1}{n} \mathbb{E}[|C(X_1, \dots, X_n)|] \leq H(X) + \epsilon$ 。

证明. 取 n 使得 $1/n \leq \epsilon$ ，并把 $Y = (X_1, \dots, X_n)$ 看作有限字母表 $\mathcal{X}^n$ 上的单个随机变量。对 $D = 2$ 应用命题 4.3，存在二元前缀码 $C : \mathcal{X}^n \rightarrow \{0, 1\}^*$ 满足

$$H(Y) \leq \mathbb{E}[|C(Y)|] < H(Y) + 1.$$

由 X_i 相互独立可得 $H(Y) = nH(X)$ ，因此

$$\frac{1}{n} \mathbb{E}[|C(Y)|] < H(X) + \frac{1}{n} \leq H(X) + \epsilon,$$

这就是第二条。至于第一条： C 是前缀码，从而唯一可译，所以它在分组拼接上的延拓是单射——解码器从左往右读编码串，每次恢复一个分组码字，于是能还原 $(x_1, \dots, x_{nk})$ 。故 C^* 是单射。

Your turn. C 的哪条性质保证诱导映射 C^* 是单射？为什么仅有非奇异性还不够？是前缀性。它让解码器无需向前看就能逐个分组地解析码流。非奇异性只区分单个分组；拼接之后两个不同的分组序列可能得到同一个字符串，例如码 $\{0, 01, 10\}$ 。

通向同一速率的两条路

路线	熵是如何出现的
分组上的 Shannon 码	码长 $\lceil -\log_2 p(x^n) \rceil$ 的平均值为 $nH(X) + O(1)$
典型集（见 §3）	用约 $nH(X)$ 个比特为约 $2^{nH(X)}$ 个典型序列编号，其余序列用一个标志位另行处理

Your turn. 沿典型集这条路线，为典型集编号大约需要每符号多少比特？非典型序列怎么办？给 $|T_{n,\epsilon}| \leq 2^{n(H(X)+\epsilon)}$ 个序列编号大约需要每符号 $H(X) + \epsilon$ 比特。非典型序列的总概率小于 ϵ ，所以即使对它们浪费地使用每符号 $\log_2 |\mathcal{X}|$ 比特，对平均值的贡献也可以忽略。

超越 i.i.d.: 熵率

上面的推导只用了一次独立性，就是把 $H(X_1, \dots, X_n)$ 写成 $nH(X)$ 。对有相关性的信源，这个量要换成一个极限。

定义 5.2 (熵率). 对平稳序列 $X_1, X_2, \dots$ ，其熵率定义为

$$\bar{H} = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, \dots, X_n),$$

该极限存在，因为 $H(X_1, \dots, X_n)$ 关于 n 是次可加的。

定理 5.3 (Shannon–McMillan–Breiman). 设 $X_1, X_2, \dots$ 是有限状态空间 $\mathcal{X}$ 上的遍历平稳序列。则当 $n \rightarrow \infty$ 时

$$-\frac{1}{n} \log p_{X^n}(X_1, \dots, X_n) \rightarrow \bar{H} \quad \text{依概率收敛,}$$

其中 $\bar{H} = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, \dots, X_n)$ 。

这就是把 AEP 中的独立性减弱为遍历平稳、把 $H(X)$ 换成 $\bar{H}$ 的版本；事实上该结论还可以加强到几乎必然收敛。有了它，典型集、分组编码以及定理 5.1 都能原样搬过来，只要把单符号熵换成熵率。

Your turn. 对 i.i.d. 序列， $\bar{H}$ 退化成什么？定理 5.3 用哪条假设取代了独立性？由可加性 $H(X_1, \dots, X_n) = nH(X_1)$ ，故 $\bar{H} = H(X_1)$ ，定理退化为 AEP。取代独立性的是「序列平稳且遍历」这一假设，正是它保证惊讶度的时间平均收敛到系综平均。

? 为什么分组能
去掉「+1」的代
价，却永远去不
掉熵这个下界？

■ 6 两个显式构造：SHANNON 码与 FANO 码

□□□□ Kraft 只保证「存在」这样的码；这里给出两份真正能动手造出码字的配方。

命题 4.3 给出了码长 $\lceil -\log_D p(x) \rceil$ ，却没有给出码字。Shannon 的配方从累积分布函数上直接读出码字；Fano 的配方则把字母表反复劈成概率尽量均衡的两半。Shannon 的版本还顺便回答了一个问题：如果按错误的分布设计码，代价恰好是一个相对熵。

何时使用： 当你需要真正写出码字，或者码是按另一个分布设计的时候，用这一节。

Shannon 码

想法是给 x 分配长度 $\ell_x = \lceil \log_D \frac{1}{p(x)} \rceil$ 的码字，并且用累积概率的 D 进制展开来决定究竟取哪一个这么长的串。

定义 6.1 (Shannon 码). 设 $\mathcal{X} = \{x_1, \dots, x_m\}$, pmf 为 p , 且 $|\mathcal{D}| = D$ 。

1. 把概率按 递减 顺序排列, $p_1 \geq p_2 \geq \dots \geq p_m$ 。
2. 令累积概率 $\alpha_k = \sum_{i=1}^{k-1} p_i$, 并把 $C(x_k)$ 定义为 α_k 的 D 进制展开的前

$$\ell_k = \lceil \log_D(1/p_k) \rceil$$

位数字。

截断误差满足 $0 \leq \alpha_k - 0.C(x_k) < D^{-\ell_k} \leq p_k$, 而 $\alpha_{k+1} - \alpha_k = p_k$, 所以不同码字对应 $[0, 1)$ 中互不相交的子区间。于是这个码是前缀码, 且码长恰好就是命题 4.3 中用到的那一组。

Your turn. 构造为什么要先把概率排序? 不排序的话论证会在哪一步失效? 排序使 $\ell_1 \leq \ell_2 \leq \dots$, 于是靠后符号所占的区间比之前每个符号的截断分辨率都要短, 任何码字都不可能是更早码字的前缀。若不排序, 一个概率小、区间长的符号可能包含后面符号的截断点, 前缀性就可能被破坏。

用错误的分布来编码

假设我们按 pmf q 造 Shannon 码, 而信源真实服从 p 。多付出的代价恰好是相对熵 $D_D(p \| q)$ 。

命题 6.2 (失配的 Shannon 码). 设 p, q 是 $\mathcal{X}$ 上的 pmf, $X \sim p$, $\mathcal{D}$ 是满足 $|\mathcal{D}| = D$ 的有限编码字母表。若 C 是按分布 q 构造的 Shannon 码, 则

$$H_D(X) + D_D(p \| q) \leq \mathbb{E}[|C(X)|] < H_D(X) + D_D(p \| q) + 1.$$

证明. 由构造知 $|C(x)| = \lceil \log_D \frac{1}{q(x)} \rceil$, 于是

$$\begin{aligned} \mathbb{E}[|C(X)|] &= \sum_x p(x) \left\lceil \log_D \frac{1}{q(x)} \right\rceil \\ &< \sum_x p(x) \left(\log_D \frac{1}{q(x)} + 1 \right) \\ &= \sum_x p(x) \left(\log_D \frac{p(x)}{q(x)} + \log_D \frac{1}{p(x)} \right) + 1 \\ &= D_D(p \| q) + H_D(X) + 1. \end{aligned}$$

下界由同一串等式得到：把上取整改为不小于其自变量，也就是把 +1 去掉。 ■

Your turn. 上面这串推导中，是哪一步代数变形制造出了散度项？把 $\frac{1}{q(x)} = \frac{p(x)}{q(x)} \cdot \frac{1}{p(x)}$ 代入并拆开对数。第一部分取平均得到 $D_D(p \| q)$ ，第二部分取平均得到 $H_D(X)$ 。

Your turn. 从命题 6.2 重新得到命题 4.3。取 $q = p$ ：此时 $D_D(p \| p) = 0$ ，两端退化为 $H_D(X) \leq \mathbb{E}[|C(X)|] < H_D(X) + 1$ 。

Fano 码 (1949)

Fano 的构造是自顶向下的：反复把字母表劈成概率尽量相等的两组，用「落在哪一组」决定下一位编码数字。

定义 6.3 (Fano 码, 二元情形). 设 p 是 $\mathcal{X} = \{x_1, \dots, x_m\}$ 上的 pmf, $X \sim p$ 。

1. 把符号排序，使得 $p_1 \geq p_2 \geq \dots \geq p_m$ 。
2. 找出使

$$\left| \sum_{i \leq r} p_i - \sum_{i > r} p_i \right|$$

最小的下标 r ，并把 $\mathcal{X}$ 劈成两组 $\mathcal{X}_0 = \{x_i : i \leq r\}$ 与 $\mathcal{X}_1 = \{x_i : i > r\}$ 。

3. 把 $\mathcal{X}_0$ 中所有码字的第一位定义为 0， $\mathcal{X}_1$ 中的定义为 1。
4. 在每一组内部重复第 (2)、(3) 步，每轮追加一位数字，直到每组只剩一个符号。

这样得到一个码 $C_F : \mathcal{X} \rightarrow \{0, 1\}^*$ 。

由于每个符号都对应劈分树的一片叶子， C_F 是 前缀 码，并且可以证明

$$\mathbb{E}[|C_F(X)|] \leq H_D(X) + \underline{2}.$$

这个界比 Shannon 的弱一个符号，而且一般而言 Fano 码并不最优：每一步贪心地平衡概率，可能被 Huffman 自底向上的构造超过。

Your turn. 按对 $\mathbb{E}[|C(X)|]$ 的保证，给本讲的三种码——Shannon、Fano、最优码 (Huffman) ——排序，并说明哪一种才真正最优。三者都以 $H_D(X)$ 为下界。Shannon 码保证 $< H_D(X) + 1$ ，Fano 码只保证 $\leq H_D(X) + 2$ ，而最优码不劣于二者，因此同样满足

$< H_D(X) + 1$ 。Shannon 码和 Fano 码一般都不是最优的；最优值由 Huffman 码达到。

? 当信源是 p 而码却按 q 设计时，衡量损失的是哪个量？