




信息论

第二讲 · 从信源符号到可译字符串

Oxford B8.4 · 2024--25

依据手写笔记整理的读填笔记

August 2, 2026

dyed in indigo, madder & weld; ruled in iron-gall. woven on LOOM.

一条主线与知识地图

□□□□

信源编码把每个信源符号替换成一个有限字符串。编码质量有两个侧面：以期望码长衡量的效率，以及在码字拼接后检验的可译性。核心设计问题是在缩短字符串的同时，保留足以识别码字边界的结构。

目前的知识地图

站	对象	要回答的问题
1	$C : \mathcal{X} \rightarrow \mathcal{D}^*$	每个信源符号由哪个有限字符串表示？
2	$L(C) = \mathbb{E}[\ell(X)]$	平均要使用多少个编码符号？
3	$C^* : \mathcal{X}^* \rightarrow \mathcal{D}^*$	码字拼接起来以后还能否唯一解码？

全文约定

信源字母表 $\mathcal{X}$ 有限， $\mathcal{D}^*$ 表示由 D 元编码字母表 $\mathcal{D}$ 中的符号组成的所有有限长字符串。例子通常取 $\mathcal{D} = \{0, 1\}$ 。

目录

一条主线与知识地图	1
第二讲 · 信源编码	3
1 编码、码长与可译性	3

第二讲 · 信源编码

先给信源符号分配字符串，再按照信源分布计算平均长度，最后提出决定性问题：拼接操作是否保留了足够的结构，使我们能够逆转编码过程？

1 编码、码长与可译性

□□□□ 一个码字标记一个符号；扩展码还必须保住整个符号序列。

编码从一个“信源符号到有限字符串”的映射开始。短字符串能够节省空间，但不同的符号，乃至不同的信源序列，都必须保持可区分。因此，期望码长与可译性必须放在一起研究。

从信源符号到码字

定义 1.1 (信源编码). 设随机变量 X 的有限字母表为 $\mathcal{X}$ 。一个 D 元信源编码是映射

$$C : \mathcal{X} \rightarrow \mathcal{D}^*,$$

其中 $\mathcal{D}^*$ 是 D 元字母表 $\mathcal{D}$ 上所有 有限长字符串 的集合。字符串 $C(x)$ 称为 x 的**码字**， $\ell(x) = |C(x)|$ 是它的码长。

例如，若 $\mathcal{X} = \{\text{红}, \text{蓝}\}$ 且 $\mathcal{D} = \{0, 1\}$ ，可以取 $C(\text{红}) = 00$ 、 $C(\text{蓝}) = 11$ 。

定义 1.2 (期望码长). 若 X 的概率质量函数为 p ，编码 C 的期望码长定义为

$$L(C) = \mathbb{E}[\ell(X)] = \sum_{x \in \mathcal{X}} p(x) \ell(x).$$

例 1.3 (与熵匹配的二进制编码). 令 $\mathcal{X} = \{1, 2, 3, 4\}$ ，其概率和码字如下：

x	1	2	3	4
$p(x)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$
$C(x)$	0	10	110	111

四个码长分别为 1, 2, 3, 3，所以

$$L(C) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = \underline{\frac{7}{4}} \text{ 比特}.$$

这里每个符号都满足 $\ell(x) = -\log_2 p(x)$ ，因此

$$H(X) = \sum_x p(x) \log_2 \frac{1}{p(x)} = \underline{\frac{7}{4}} \text{ 比特} = L(C).$$

Your turn. 为什么这个例子中的 $L(C) = H(X)$ 不需要特殊的平均技巧? 这个等式对每一项都成立: 每个码长都满足 $\ell(x) = -\log_2 p(x)$ 。两边乘以 $p(x)$ 后求和, 立即得到 $L(C) = H(X)$ 。

三个层次的可译性

定义 1.4 (非奇异码). 若不同信源符号具有不同码字, 则称编码 C 为**非奇异码**:

$$x \neq x' \implies C(x) \neq C(x').$$

等价地说, C 是一个 单射。

非奇异性只保护单个符号。为了编码符号序列, 将 C 按照拼接方式扩展为

$$C^* : \mathcal{X}^* \longrightarrow \mathcal{D}^*, \quad C^*(x_1 x_2 \cdots x_n) = C(x_1)C(x_2) \cdots C(x_n).$$

定义 1.5 (唯一可译码). 若扩展码 C^* 是非奇异的, 则称 C 为**唯一可译码**。换言之, 每个编码后的字符串至多对应一个产生它的信源序列。

定义 1.6 (前缀码). 若任何码字都不是另一不同码字的前缀, 则称该编码为**前缀码**, 也称即时码。

每个前缀码都是唯一可译码, 每个唯一可译码都是非奇异码:

$$\{\text{前缀码}\} \subset \{\text{唯一可译码}\} \subset \{\text{非奇异码}\}.$$

反方向一般不成立。

例 1.7 (唯一可译但不是前缀码). 对 $\mathcal{X} = \{A, B, C, D\}$, 考虑

$$C(A) = 0, \quad C(B) = 01, \quad C(C) = 011, \quad C(D) = 111.$$

它不是前缀码, 因为 0 是 01 和 011 的前缀; 但它仍是唯一可译码。从较长码字中删去开头的 0, 只会留下 1 或 11; 再将这些后缀与 111 比较, 只会使 $1 \leftrightarrow 11$ 来回转换, 永远不会得到空后缀。因此不会有两个信源序列产生相同的拼接结果。

Your turn. 编码 $\{0, 01, 10\}$ 是非奇异码, 却不是唯一可译码。请给出两个编码结果相同的不同信源序列。 AC 与 BA 都编码为 010。